

Análise Comparativa de Algoritmos de Busca em Espaço de Estados e Otimização Local

João Marcelo Gonçalves Lisboa* e Sergio Henrique Quedas Ramos*†
Centro Federal de Educação Tecnológica de Minas Gerais (CEFET-MG)
Divinópolis, Minas Gerais, Brasil

Resumo—Este artigo apresenta uma análise experimental e comparativa de algoritmos de Inteligência Artificial em dois domínios: *busca em espaço de estados* (Busca no Labirinto) e *otimização local* (Problema das 8 Rainhas). No Trabalho 1, implementações de BFS, DFS, UCS, Busca Gulosa e A* foram comparadas, analisando a eficiência de duas heurísticas (Manhattan e Chebyshev). Os resultados confirmam que o A* com Manhattan oferece a melhor combinação de optimalidade garantida e menor consumo de recursos (*15 nós expandidos*). No Trabalho 2, o algoritmo *Hill Climbing* foi analisado com variações de Movimentos Laterais e Random-Restart. Demonstrou-se que a combinação de Reinícios Aleatórios e Movimentos Laterais é a mais eficiente, elevando a taxa de sucesso para 100% e reduzindo a média de reinícios de 7.3 para 0.6. Conclui-se que a escolha da heurística e das estratégias de otimização local são cruciais para a eficiência e robustez dos sistemas de IA, validando empiricamente as garantias teóricas de cada classe de algoritmo.

Index Terms—Inteligência Artificial, Busca A*, Hill Climbing, Problema das 8 Rainhas, Busca no Labirinto.

I. INTRODUÇÃO

A resolução de problemas através da Inteligência Artificial (IA) fundamenta-se na busca eficiente por soluções dentro de um espaço de estados definido. Este estudo técnico-científico consolida os resultados obtidos em dois trabalhos práticos, abrangendo métodos de busca global (Trabalho 1) e métodos de otimização local (Trabalho 2), aplicados aos clássicos problemas do Labirinto e das 8 Rainhas. O objetivo é quantificar a performance, as garantias de completude e optimalidade, e a eficiência computacional das técnicas exploradas.

II. METODOLOGIA EXPERIMENTAL

A metodologia adotada consistiu na implementação e avaliação empírica dos algoritmos em ambientes controlados, com foco na mensuração de métricas de eficiência (tempo/nós e memória).

A. Problema 1: Busca em Labirinto

1) *Algoritmos e Ambiente*: Foram implementados cinco algoritmos de busca: *Breadth-First Search* (BFS), *Depth-First Search* (DFS), *Uniform-Cost Search* (UCS), Busca Gulosa (Greedy Best-First) e A*. O ambiente de teste foi o labirinto fornecido na Figura 1 do enunciado do trabalho, com custos de movimento uniformes.

2) *Heurísticas e Métrica*: Para as buscas informadas, foram comparadas duas heurísticas:

- **Distância de Manhattan** (h_{man}): Soma da diferença absoluta entre as coordenadas ($|x_1 - x_2| + |y_1 - y_2|$), que é admissível e consistente para movimentos ortogonais.
- **Distância de Chebyshev** (h_{cheb}): Máximo das diferenças absolutas ($\max(|x_1 - x_2|, |y_1 - y_2|)$), que é admissível, mas menos informada em um grid sem movimentos diagonais.

As métricas de avaliação foram: **Custo do Caminho**, **Nós Expandidos** (custo de tempo) e **Pico de Memória** (máximo de nós na fila/fronteira).

B. Problema 2: Otimização Local (8 Rainhas)

1) *Algoritmo e Objetivo*: O problema das 8 Rainhas foi resolvido utilizando o algoritmo *Hill Climbing* (HC), com o objetivo de minimizar a função de custo h , que representa o número de pares de rainhas em conflito (ameaçando-se).

2) *Variações e Simulação*: O desempenho do HC foi avaliado em 4 configurações, com 100 execuções por configuração, partindo de estados iniciais aleatórios:

- 1) **HC Simples**: Movimento apenas para estados vizinhos com custo estritamente menor ($h' < h$).
- 2) **HC Lateral**: Permite Movimentos Laterais (custo igual, $h' = h$) com um limite de $L = 10$ para escapar de platôs.
- 3) **HC Random-Restart (RR) Simples**: Reinício aleatório da busca a partir de um novo estado inicial sempre que um máximo local é atingido.
- 4) **HC RR Lateral**: Combinação das estratégias 2 e 3, otimizando a busca individual antes de um reinício.

As métricas avaliadas foram: **Taxa de Sucesso** (%), **Média de Reinícios** e **Média de Passos** (custo de tempo).

III. RESULTADOS DO TRABALHO 1

A. Análise Quantitativa da Busca

A Table I resume o desempenho dos algoritmos, sendo o custo ótimo de solução 11.00.

B. Discussão da Busca Informada

O **A* com a heurística de Manhattan** foi o algoritmo superior. Ele não apenas garantiu o caminho ótimo (propriedade do A* com heurística admissível), mas o fez com a menor quantidade de nós expandidos (15) e o menor uso de memória (26) entre todos os algoritmos, incluindo o BFS e o UCS (19 nós expandidos).

Tabela I: Comparação de Métricas dos Algoritmos de Busca no Labirinto.

Algoritmo	Custo	Nós Exp.	Memória	Optimalidade
BFS	11.00	19	34	Sim
DFS	21.00	36	37	Não
UCS	11.00	19	34	Sim
Gulosa (h_{man})	11.00	15	26	Não*
A* (h_{man})	11.00	15	26	Sim
Gulosa (h_{cheb})	11.00	20	31	Não*
A* (h_{cheb})	11.00	20	31	Sim

* Achou o ótimo por acaso, mas não é garantido.

A comparação entre heurísticas também é notável: a h_{man} , sendo mais precisa para movimentos em 4 direções, exigiu menos busca (15 nós) do que a h_{cheb} (20 nós), demonstrando o impacto direto de uma heurística bem ajustada na eficiência.

DFS (Busca em Profundidade) - Custo: 21 | Nós Exp: 36




Figura 1: Visualização do caminho e nós expandidos do DFS. O algoritmo encontrou um caminho subóptimo (custo 21.00) devido à sua natureza de busca em profundidade, contrastando com a precisão dos algoritmos ótimos.

IV. RESULTADOS E ANÁLISE DO TRABALHO 2

O Trabalho 2 avaliou a capacidade do *Hill Climbing* de superar os desafios da otimização local, como máximos locais e platôs, no espaço de estados do Problema das 8 Rainhas.

A. Análise Detalhada do Hill Climbing

Os resultados em Table II destacam a fragilidade do HC simples e a necessidade das estratégias de meta-heurística.

1) *O Efeito do Random-Restart (RR)*: O RR elevou a taxa de sucesso de 60% (HC Lateral) para **100%**, confirmando sua função essencial em tornar o Hill Climbing probabilisticamente completo. Isso acontece porque a cada reinício, o algoritmo explora uma nova "bacia de atração", aumentando a chance de encontrar a solução global (custo $h = 0$).

Tabela II: Comparação de Métricas do Hill Climbing (100 Runs).

Configuração	Sucesso (%)	Avg Reinícios	Avg Passos
HC Simples	14.00	0.0	5.1
HC Lateral (L=10)	60.00	0.0	8.9
HC RR Simples	100.00	7.3	34.7
HC RR Lateral (L=10)	100.00	0.6	18.4

2) *Otimização de Eficiência (Movimentos Laterais)*: A combinação do HC RR com Movimentos Laterais (**HC RR Lateral**) se destacou pela eficiência.

- **Redução de Reinícios**: O Movimento Lateral permite que a busca explore um platô por até 10 passos. Isso resultou na redução da média de reinícios de 7.3 (HC RR Simples) para apenas 0.6. Cada reinício representa um alto custo de tempo, e a capacidade de resolver um problema com menos de um reinício em média indica uma robustez significativamente maior.
- **Custo Total de Busca**: A redução dos passos médios acumulados de 34.7 para 18.4 demonstra que, embora o Movimento Lateral adicione passos em buscas individuais (de 5.1 para 8.9 no HC sem RR), o custo total do processo de *Random-Restart* é drasticamente menor.

O resultado final valida que o **Hill Climbing Random-Restart com Movimentos Laterais** é a estratégia mais eficiente para a otimização local em espaços complexos com múltiplos ótimos locais, pois equilibra a completude do RR com a eficácia da busca individual aprimorada.




Figura 2: Taxa de Sucesso das quatro configurações de Hill Climbing. Apenas as estratégias com Random-Restart atingiram 100% de sucesso.

V. CONCLUSÃO

O presente trabalho consolidou os resultados de duas classes fundamentais de algoritmos de IA: busca em grafo e otimização local.

Na **Busca em Grafo (Trabalho 1)**, validou-se que o **A* com a Heurística de Manhattan** é a solução ideal, superando os algoritmos de busca cega e informada menos adequados em termos de eficiência e garantias. A escolha da heurística admissível e consistente, ajustada à topologia do problema (4

direções), provou ser o fator determinante para a minimização do custo computacional.

Na **Otimização Local (Trabalho 2)**, demonstrou-se empiricamente que algoritmos de subida de encosta (Hill Climbing) são incompletos em sua forma simples. A combinação do **Random-Restart com Movimentos Laterais** foi identificada como a estratégia mais robusta e eficiente, pois minimiza a intervenção custosa do reinício aleatório (redução de 7.3 para 0.6 reinícios) ao aumentar a capacidade de exploração de cada busca individual.

REFERÊNCIAS

- [1] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th ed. Pearson, 2020.
- [2] S. J. Russell and P. Norvig, "AIMA-Python: Python implementation of algorithms from "Artificial Intelligence: A Modern Approach".", GitHub, 2023. [Online]. Available: <https://github.com/aimacode/aima-python>.
- [3] A. J. Patel, "Introduction to A*," Red Blob Games, 2023. [Online]. Available: <https://www.redblobgames.com/pathfinding/a-star/introduction.html>.
- [4] S. J. Russell, "The Eight Queens Problem," in *AI: A Modern Approach*, 4th ed., 2020, pp. 110-112.
- [5] N. J. Nilsson, *Principles of Artificial Intelligence*. Tioga Publishing Company, 1980.

VI. CRÉDITOS E DECLARAÇÃO DE AUTORIA

A. Autores e Papéis

- **João Marcelo Gonçalves Lisboa:** Implementação da arquitetura de busca BFS, DFS, UCS, A* e Hill Climbing, desenvolvimento das heurísticas e variações, execução dos experimentos e escrita das Sections II and V.
- **Sergio Henrique Quedas Ramos:** Ficou responsável pela documentação (devido a problemas médicos).

B. Uso de IA

Ferramenta de IA (Google Gemini) utilizada para: i) Debug (correção de erros de código e sintaxe); ii) Geração da estrutura robusta do relatório em LATEX (formato IEEEtran); iii) Geração das sugestões de análise e discussão dos resultados.

C. Declaração

Confirmamos que o código entregue foi desenvolvido pelos autores, respeitando as políticas da disciplina.